

倪硕洋

Phone:18360255516 | Email:nishuoyang2023@163.com

教育经历

郑州轻工业大学 - 本科
数据科学与大数据技术

(2023.09-2027.07)

项目经验

一、多源竞品监控与异常告警 Agent (独立开发)

项目描述:

一个 LLM 驱动的多源竞品监控与异常告警系统，自动巡检 **GitHub Release**、**电商商品价格**、**App Store 评分** 三类数据源，完成「采集 → 基线对比 → 异常判定 → 告警推送 → 结构化报告」的全链路闭环。核心设计哲学：**LLM 只做决策与编排，所有精确计算由确定性代码执行**，杜绝大模型幻觉算错价格的零容忍事故。

技术栈: Python、LangGraph、OpenAI 兼容 LLM API、SQLite (WAL)、Jinja2、tenacity、APScheduler、pytest、GitHub Actions CI。

主要工作:

- 基于 **LangGraph** 搭建「采集分析 → 路由 → 人工确认 → 通知 → 报告」编排图，通过 **Function Calling** 接入 **17 个确定性工具**，LLM 在 **ReAct** 循环中自主完成采集与告警创建，数值比较统一收敛到唯一的 **compare_metrics** 代码入口；
- 设计 **策略模式采集器** 架构，新增数据源仅需继承基类并注册一行，统一 **{"product_id", "metric", "value", "collected_at"}** 输出格式，已接入 **GitHub / 电商价格 / App Store** 共 **4 类数据源**，网络请求统一 **tenacity 指数退避重试**；
- 实现基于 **interrupt()** 的 **Human-in-the-Loop 门控**：critical 告警**确定性暂停**等待人工批准、warning/info 直通，配合 **SqliteSaver checkpoint (WAL 模式) 持久化**，进程崩溃后可从断点 resume 继续，不丢上下文；
- 实现**双通道异常检测**：阈值比较抓「幅度」异常、**Isolation Forest** 抓「形状」异常；告警按 **product+type 24h 自动去重**，重复出现的 warning **自动升级为 critical**，避免告警轰炸；
- 实现**飞书/钉钉 Webhook 推送** (HMAC 加签)、**Jinja2 渲染 Markdown/HTML 结构化报告**，并通过 **eval_runs** 表自动统计每次运行的**成功率与延迟**，形成客观自我评估闭环；配套 **pytest 64 项测试**与 **GitHub Actions CI**，支持 **APScheduler 定时巡检**与**产品注册表管理**。

二、DocRAG · 垂直领域智能文档问答系统 (独立开发)

项目描述:

一套完整的 **RAG 工程实践**：上传 PDF/DOCX/PPT 等 **8 种格式**文档，经「语义切分 → 混合检索 → Query 增强 → Rerank 精排」后，由 LLM **流式生成带引用来源**的回答。前后端分离：**FastAPI + LangChain** 后端、**Vue 3 + Vite** 前端，向量库采用 **Milvus (Docker Compose)**，LLM/Embedding/Rerank 均接入 OpenAI 兼容云 API。

技术栈: Python、FastAPI、LangChain、Vue 3、Vite、Tailwind CSS、Milvus、SQLite、RAGAS、Docker Compose。

主要工作:

- 实现**向量 + BM25 混合检索**双路召回 (**rank_bm25 + jieba** 中文分词)，多查询结果合并去重，互补解决「语义相似但无关键词」与「关键词精确但语义跑偏」问题，专有名词与代码片段不漏检；
- 实现 **Query 改写补指代 + HYDE 假想答案**并行增强扩大召回，失败自动降级原 query；**Rerank 精排** (**bge-reranker-v2-m3** 交叉编码) 坚持用**原始 query**，贴合用户本意；
- 设计**双分块策略**：短文按句子 embedding 相似度语义断块 (均值-1.5σ 阈值、碎块合并)，长文档固定切分，**chunk_type** 标记共存，兼顾精度与成本；
- 实现 **SSE 逐字流式问答** (打字机渲染 + 思考动画 + 引用来源卡片)，检索置于 **asyncio.to_thread** 防阻塞事件循环；**SQLite** 持久化对话记忆 (存 50 轮取 6 轮)，刷新页面自动续聊；
- 搭建 **RAGAS 离线评估体系**：自动生成中文测试集 + **faithfulness/answer_relevancy/context_precision/context_recall** **四项指标**量化，产出 Markdown/JSON 报告，实测 **忠实度 0.955、答案相关性 0.880、上下文召回 0.850、上下文精度 0.895**。

技能与证书

- 后端**：熟悉 **Python**，掌握 **FastAPI** 框架，能够使用其开发 RESTful API 后端服务；
- 前端**：了解 **HTML / CSS / JavaScript** 前端基础，能够编写页面并进行简单交互开发；
- AI 应用**：熟悉 **LangChain/Langgraph** 大模型开发框架，了解从 **Prompt 设计**、模型调用、上下文构建、工具接入到服务化部署的完整链路，具备 **RAG 与 Agent** 应用开发的项目经验；
- RAG / 检索**：熟悉 **Embedding**、文档切片与 **RAG** 基本流程，了解混合检索、Query 增强、**Rerank 精排**与检索质量评估；
- AI Agent**：熟悉 **ReAct、Tool Calling** 等 Agent 核心机制，了解 **Human-in-the-Loop**、上下文记忆及 Agent 工具调用链路；
- 数据库**：了解 **MYSQL、PostgreSQL** 等主流数据库，了解向量数据库在知识检索和语义搜索场景中的使用方式；
- AI 辅助编程**：熟练使用 **Claude Code** 等 AI 辅助编程工具；
- 工程**：熟悉 **Docker**，使用 **Docker** 部署过个人网站，熟悉 **Git** 版本管理与协作开发；
- 证书**：**CET-4**，**蓝桥杯全国软件和信息技术专业人才大赛 省一等奖**；